冯成宽

18789200286@163.com · (+86) 187-8920-0286 · acmfck

研究兴趣：大模型高效推理（低比特量化）、多模态长视频理解



教育背景

厦门大学 2027.09 – 2030.06（推免拟录取）

人工智能　硕士研究生（MAC Lab）

三峡大学 2023.09 – 至今

计算机科学与技术 （本科在读） 加权平均分：91.47 (11/245)

主修课程：C 语言程序设计 (100)、数据结构 (99)、操作系统 (99)、计算机组成与结构 (96) 等

英语水平：CET-6 (517)、CET-4 (571)

竞赛荣誉

国际级：第 50 届 ICPC 亚洲区域赛：银奖（西安，2025.10）、铜奖（武汉，2025.11）

国家级：ICPC 全国邀请赛：银奖（西安，2025.05）、铜奖（武汉，2026.05）、铜奖（南昌，2025.05）

国家级：第十七届蓝桥杯 C/C++ 程序设计大学 B 组全国总决赛：国家一等奖（2026.06）、省一等奖（2026.04）

科研项目

大模型推理优化与低比特量化研究 2026.06 – 至今

厦门大学 MAC Lab Qwen3-8B、W4A4、FlatQuant、GPTQ、SpQR

在 Qwen3-8B、W4A4、nsamples=128 设置下，验证 block_diag + GPTQ 将 WikiText-2 PPL 从 10.8440 降至 10.5379；围绕 block_diag 与 kronecker 旋转结构，构建 RTN、GPTQ、SpQR 三类后端对照实验。

构建统一量化评测流程，完成 calibration cache、FlatQuant 校准、W4A4 量化与 lm-eval 多任务评测，并统一实验配置以保证不同量化后端间的可复现和可对比。

分析 WikiText-2 PPL 与 lm-eval 结果，发现 block_diag 对比 kronecker 的收益随量化后端而变化，为后续旋转结构设计与后端适配提供依据。

项目经历

Video-RAG Ultra：基于多模态检索增强的长视频理解系统 2025.12 – 2026.02

独立完成 Python、PyTorch、OpenCLIP、faster-whisper、bge-m3、FAISS、Qwen2.5-VL

独立实现 Video-RAG Ultra 长视频问答系统，在 Video-MME 无字幕全量评测上取得 60.89% 准确率，short、medium、long 子集分别为 71.78%、58.44%、52.44%。

针对长视频直接输入显存开销大、长上下文易遗忘的问题，设计“证据召回 + 时间组织 + 多模态推理”流程；构建 OpenCLIP 视觉检索与 faster-whisper + bge-m3 音频检索，使用 FAISS 建立跨模态索引，并结合 Qwen2.5-VL 完成 MCQ logprob 打分。

技能与能力

大模型量化与评测：W4A4、GPTQ、SpQR、RTN、lm-eval、WikiText-2 PPL、PageAttention、Continuous Batching

多模态检索与视频理解：OpenCLIP、faster-whisper、bge-m3、FAISS、Video-MME

工程与算法实现：Python、PyTorch、C/C++、Linux、Git、LaTeX

其他经历

三峡大学 ACM 集训队队长；助理班主任；获校优秀共青团员、校级奖学金、三好学生等荣誉。